基于集对分析的马尔可夫链入库流量分布特征动态分析

李爱云，赵雪花

（太原理工大学水利科学与工程学院，山西 太原 030024）

摘 要：不确定性问题具有随时间动态变化，且具有多样性、变异性和复杂性及不精确性。其中许多不确定性问题呈现某种趋势的非平稳随机过程，即具有将来与过去无关的特性，而对这类问题的预测研究采用基于集对分析的马尔可夫链的动态预测模型。根据小浪底水库1919年～1974年的入库流量资料，应用有序样品聚类原理将入库流量分成枯水、偏枯、中水、偏丰、丰水5种等级区间；以各滞时步长马尔可夫链的集对权重，预测1973年～1974年的入库流量，将其所在状态区间与实测值进行对比。结果表明，基于集对分析的马尔可夫链模型对小浪底水库入库流量预测精度较高。

关键词：集对分析；马尔可夫链；入库流量；马氏性检验

Dynamic Analysis of Inflow Distribution by Using Markov Chain Based on Set Pair Analysis

LI Aiyun, ZHAO Xuehua

(College of Water Conservancy, Taiyuan University of Technology, Taiyuan 030024, Shanxi, China)

Abstract: The uncertainty has a dynamic process over time and it also has diversity, variability, complexity and imprecision. Many uncertainties present a trend of non-stationary random process, which has a feature of no relationship between future and past. For forecasting this type of uncertainty problem, the dynamic analysis model based on Markov Chain of Set Pair Analysis is used in here. According to the actual inflow data of Xiaolangdi Reservoir from 1919 to 1974, the principle of sequence sample cluster is used to divide the inflow sequence into five conditions, including drought, lean drought, normal, lean wet and wet, and then the inflow of Xiaolangdi Reservoir in 1973-1974 is forecasted by the set pair weights of Markov Chain with different lag time steps. The forecasting results are compared with actual measured data. The comparison shows that the Markov Chain model based on Set Pair Analysis can predict the inflow of Xiaolangdi Reservoir with higher precision.

Key Words: Set Pair Analysis; Markov Chain; reservoir inflow; Markov property testing

中图分类号：TV122.5 **文献标识码：**A **文章编号：**0559-9342(2016)11-0016-04

0 引 言

受到众多因素的影响，年径流预测具有很大的不确定性，且年径流的预测因子的结构是动态复杂的，其具有多样性、变异性及不精确性。长期以来，水文预测工作者依据大量的实测水文资料，努力尝试寻求水文资料的各种关系。包括：在时间演变过程中前后关系；与主要影响因素的关系；空间分布上各种要素的关系。通过这些关系以达到对水文资料的分析计算、预测、评价及决策[1-3]。马尔可夫于1907年提出的马尔可夫链预测方法，根据状态之间的转移概率来推算系统未来的发展趋势。Zekai Sen应用马尔可夫链对洪水来水情况进行预测[4-5]，预测结果合理可靠。本文应用集对分析原理分析原序列和各滞时后的序列之间的确定性和不确定性，提高马尔可夫链权重的确定，探讨集对分析与马尔可夫链的耦合动态预测模型。

收稿日期：2015-12-21

基金项目：山西省科技攻关基金资助项目(20140313023-4)

作者简介：李爱云(1977—)，女，山西阳泉人，讲师，硕士，主要从事水文预报研究与教学工作.

1 基于集对分析的马尔可夫链动态预测模型[6]

1.1 步骤1——划分状态空间

先把样本序列从小到大进行排序，再根据有序样品聚类法的方法来划分入库流量变化区间，这样可以充分地考虑径流序列的数据结构。即确定了马尔可夫链的状态空间。其基本原理为：如果用数据 x_1，x_2，…，x_n 表示 N 个有序的样品，则每一类一定是这样的形式：$\{x_n, x_{n+1}, \cdots, x_{n+k}\}$。其中，$1 \leqslant n \leqslant N$，$k \geqslant 0$ 且 $n+k \leqslant N$。也就是同类样品一定是相互近邻的。有序聚类的 Fisher 的算法如下：把序列 x_1，x_2，…，x_n 按某一归类 $\{x_n, \cdots, x_m\}$，$m \geqslant n$。定义均值向量

$$\bar{X}_{mn} = \frac{1}{m-n+1}\sum_{t=n}^{m} x_t \tag{1}$$

式中，m(也称状态)为序列 x 的个数，m 也称之为状态；n 与 $n+k$ 是属于 N 个有序样品的个数，但均小于 N；k 是滞时。

各变量间的差异性用以下面模型来衡量。即

$$D(n,m) = \sum_{t=n}^{m} (x_t - \bar{x}_{mn})'(x_t - \bar{x}_{mn}) \tag{2}$$

式中，$D(n, m)$ 是分类的直径，其值的大小与段内变量之间的差异有关，其值越小表示段内变量的差异越小；反之，则表示差异越大。x_t 表示在 t 时刻的序列值。

1.2 步骤2——确定各滞时步长的集对权重

将 n 个有序变量分为 f 类，其分法为 $P(n, f)$：$\{m_1, m_{1+1}, \cdots, m_{2-1}\}$；$\{m_2, m_{2+1}, \cdots, m_{3-1}\}$；…，$\{m_K, m_{K+1}, \cdots, m_n\}$。其分类误差为

$$L[P(n,f)] = \sum_{n=1}^{f} D(m_n, m_{n+1}-1) \tag{3}$$

$L[P(n, f)]$ 最小时就是最优分割法。f 一般可以根据 $L[P(n, f)]$ 和 f 的关系曲线图确定，曲线拐点处的 f 值即为最优分类数。

如原样本序列状态空间 $A = [x_1, x_2, \cdots, x_N]$，则原样本序列滞时 k 指延迟的时间，亦即滞时步状态空间为 $B_k = [x_{k+1}, x_{k+2}, \cdots, x_N]$ $(k = 1, 2, \cdots, K)$。将集合 A 分别与集合 B_k 构成集对 $H(A, B_k)$ 进行同异反分析，得出相应的联系度表达式。这里把研究对象分成5类，把元素处于同一等级的定义为相同，其个数是 S；相差一级的(如Ⅰ与Ⅱ，Ⅱ与Ⅲ)定义为差异一，其个数是 F_1；相差两个等级(如Ⅰ与Ⅲ，Ⅱ与Ⅳ)的定义为差异二，其个数是 F_2；相差三个等级及其以上(如Ⅰ与Ⅳ，Ⅱ与Ⅴ)定义为相反，其个数是 P，相应的联系数

$$\mu_k = \frac{S}{N-k} + \frac{F_1}{N-k}i_1 + \frac{F_2}{N-k}i_2 + \frac{P}{N-k}j \tag{4}$$

式中，$\mu_k \in [-1, 1]$。为了求得指标权重，需要对联系数进行转换。即

$$U_k = 0.5 \times \mu_k + 0.5 \tag{5}$$

式中，U_k 是相对联系数值，其取值范围为[0，1]。滞时 k 步的马尔可夫链的权重

$$\omega_k = U_k / \sum_{k=1}^{K} U_k \tag{6}$$

式中，K 为最大滞时阶数。

1.3 步骤3——马氏性检验

设为1步状态转移频率矩阵，于是

$$P_{.n} = \sum_{m=1}^{K} f_{mn} / \sum_{m=1}^{K}\sum_{n=1}^{K} f_{mn} \text{ 且 } P_{mn} = f_{mn} / \sum_{m=1}^{K} f_{mn} \tag{7}$$

当 N 较大时，统计量

$$\chi^2 = 2\sum_{m=1}^{K}\sum_{n=1}^{K} f_{mn}\left|\ln\frac{P_{mn}}{P_{.n}}\right| \tag{8}$$

其服从自由度为 $(K-1)^2$ 的 χ^2 分布，对于给定的显著水平 α，当 χ^2 大于查表获得的分位点 $\chi^2_\alpha((K-1)^2)$，这时序列符合马氏性，可以用马尔可夫链预测模型进行预测。

1.4 步骤4——预测概率

由步骤2得入库流量状态序列值，经比较分析不同步长入库流量的状态序列值，得到马尔可夫链不同步长的状态转移概率矩阵。这时将不同步长的马尔可夫链的状态转移概率矩阵分别结合其前面若干时段实测值的状态，可预测该时段的状态概率 $P_m^{(k)}$，则相同步长的状态概率加权和可作为入库流量在该状态下的预测概率 P_m。即

$$P_m = \sum_{k=1}^{K} \omega_k P_m^{(k)} \tag{9}$$

根据 $\max\{P_m \mid m = 1, 2, \cdots, M\}$ 所对应的状态，作为该时段入库流量的预测状态。待该时段之后，将其带入到原来的序列之中，再重复以上步骤即可预测下时段指标值状态。

2 工程实例

现以1919年～1972年的资料预测1973年的入库流量，其步骤如下。

2.1 确定马尔可夫链的状态空间

把1919年1972年的入库流量(见表1)按从小到大的顺序排列，按最优分割法求出误差函数 $L[P(n, e]$ 与分类数 e 关系(见图1)。根据图1，把入库流量分为5个等级区间比较合理(见表2)。

2.2 计算马尔可夫链的权重

按1.2确定各滞时步长的马尔可夫链的集对权重。由表2可得，原入库流量的状态序列 $A = [x_1, x_2, \cdots, x_N]$ 分别与原入库流量 k 步滞时的状态序列 $B_k = [x_{k+1}, x_{k+2}, \cdots, x_N]$ $(k = 1, 2, \cdots, K)$ 构成集对

表1　1919年~1972年入库流量序列及状态　　m^3/s

年份	入库流量	状态	年份	入库流量	状态	年份	入库流量	状态
1919年	251	Ⅲ	1937年	493	Ⅴ	1955年	379	Ⅳ
1920年	267	Ⅲ	1938年	399	Ⅳ	1956年	288	Ⅲ
1921年	300	Ⅲ	1939年	175	Ⅱ	1957年	171	Ⅱ
1922年	170	Ⅱ	1940年	412	Ⅴ	1958年	444	Ⅴ
1923年	183	Ⅱ	1941年	203	Ⅱ	1959年	309	Ⅳ
1924年	119	Ⅰ	1942年	212	Ⅱ	1960年	217	Ⅱ
1925年	170	Ⅱ	1943年	372	Ⅳ	1961年	438	Ⅴ
1926年	130	Ⅰ	1944年	270	Ⅲ	1962年	311	Ⅳ
1927年	154	Ⅱ	1945年	309	Ⅳ	1963年	405	Ⅴ
1928年	101	Ⅰ	1946年	363	Ⅳ	1964年	574	Ⅴ
1929年	167	Ⅱ	1947年	297	Ⅲ	1965年	188	Ⅱ
1930年	126	Ⅰ	1948年	251	Ⅲ	1966年	404	Ⅴ
1931年	120	Ⅰ	1949年	478	Ⅴ	1967年	551	Ⅴ
1932年	147	Ⅰ	1950年	256	Ⅲ	1968年	409	Ⅴ
1933年	262	Ⅲ	1951年	311	Ⅳ	1969年	221	Ⅱ
1934年	263	Ⅲ	1952年	248	Ⅲ	1970年	272	Ⅲ
1935年	308	Ⅳ	1953年	242	Ⅲ	1971年	213	Ⅱ
1936年	250	Ⅲ	1954年	367	Ⅳ	1972年	197	Ⅱ

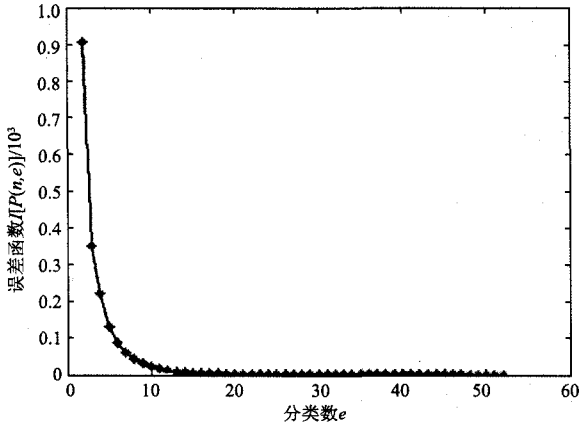

图1　误差函数 $L[P(n, e)]$ 与分类数 e 关系

表2　入库流量等级区间划分　　m^3/s

流量区间	级别	状态
$X<152$	枯水年	Ⅰ
$152\leqslant X<226$	偏枯年	Ⅱ
$226\leqslant X<304$	中水年	Ⅲ
$304\leqslant X<402$	偏丰年	Ⅳ
$X\geqslant 402$	丰水年	Ⅴ

$H(A,B_k)$ $(k=1\sim5)$ 进行同异反分析，得出相应的联系度表达式

$$\mu_1=0.3208+0.4151i_1+0.1509i_2+0.1132j$$

$$\mu_2=0.3269+0.3846i_1+0.1731i_2+0.1154j$$

$$\mu_3=0.3725+0.3333i_1+0.1961i_2+0.0981j$$

$$\mu_4=0.26+0.34i_1+0.26i_2+0.14j$$

依据经验，取 $i_1=0.5$，$i_2=-0.5$，$j=-1$ 得出联系数 $U_k=(0.3397, 0.3172, 0.343, 0.16, 0.2245)$，由式(5)得到相对联系度数值 $U_k=(0.6698, 0.6586, 0.6715, 0.58, 0.6122)$，再根据式(6)得到各滞时步长的马尔可夫链的权重 $\omega_k=(0.2098, 0.2063, 0.2104, 0.1817, 0.1918)$。

2.3　马氏性检验

通过统计得出各种步长的状态转移概率矩阵为

$$P^{(1)}=\begin{bmatrix}0.333 & 0.500 & 0.167 & 0.000 & 0.000\\ 0.250 & 0.250 & 0.083 & 0.083 & 0.334\\ 0.000 & 0.231 & 0.308 & 0.308 & 0.153\\ 0.000 & 0.200 & 0.500 & 0.200 & 0.100\\ 0.000 & 0.300 & 0.100 & 0.300 & 0.300\end{bmatrix}$$

$$P^{(2)}=\begin{bmatrix}0.667 & 0.000 & 0.333 & 0.000 & 0.000\\ 0.167 & 0.417 & 0.083 & 0.250 & 0.083\\ 0.000 & 0.153 & 0.308 & 0.386 & 0.153\\ 0.000 & 0.100 & 0.300 & 0.200 & 0.400\\ 0.000 & 0.500 & 0.100 & 0.100 & 0.300\end{bmatrix}$$

$$P^{(3)}=\begin{bmatrix}0.167 & 0.333 & 0.333 & 0.167 & 0.000\\ 0.334 & 0.334 & 0.083 & 0.083 & 0.166\\ 0.077 & 0.232 & 0.307 & 0.307 & 0.077\\ 0.000 & 0.300 & 0.100 & 0.400 & 0.200\\ 0.000 & 0.200 & 0.200 & 0.100 & 0.500\end{bmatrix}$$

$$P^{(4)}=\begin{bmatrix}0.333 & 0.167 & 0.333 & 0.167 & 0.000\\ 0.250 & 0.334 & 0.083 & 0.250 & 0.083\\ 0.077 & 0.308 & 0.231 & 0.231 & 0.153\\ 0.000 & 0.200 & 0.200 & 0.200 & 0.400\\ 0.000 & 0.400 & 0.300 & 0.100 & 0.200\end{bmatrix}$$

$$P^{(5)}=\begin{bmatrix}0.333 & 0.000 & 0.333 & 0.167 & 0.167\\ 0.250 & 0.250 & 0.333 & 0.167 & 0.000\\ 0.077 & 0.308 & 0.231 & 0.153 & 0.231\\ 0.000 & 0.100 & 0.300 & 0.300 & 0.300\\ 0.000 & 0.500 & 0.000 & 0.200 & 0.300\end{bmatrix}$$

根据表1和式(8)得到统计量 $\chi^2=40.00$，查表可得分位点 $\chi^2_{\alpha=0.05}(16)=26.296$，入库流量满足马氏性。

2.4　入库流量预测

根据1968年~1972年的入库流量及对应的状态转移矩阵对1973年的入库流量进行预测(见表3)。

将 $\max\{P_m\}=0.343$，这时 $m=2$，也就是1973年的入库流量预测状态为Ⅱ为偏枯年($152\leqslant X<226$ m^3/s)，与1973年的入库流量197 m^3/s 相吻合。

同理，以1969年~1973年的入库流量资料，按照上面的步骤预测1974年的年径流状态(见表4)。

将 $\max\{P_m\}=0.313$，这时 $m=2$，也就是1974

表 3　1973 年入库流量预测

年份	状态	滞时/a	集对权重	各状态流量预测概率					概率来源
				Ⅰ	Ⅱ	Ⅲ	Ⅳ	Ⅴ	
1972 年	Ⅱ	1	0.209 8	0.25	0.25	0.083	0.083	0.334	$P^{(1)}$
1971 年	Ⅱ	2	0.206 3	0.167	0.417	0.083	0.25	0.083	$P^{(2)}$
1970 年	Ⅲ	3	0.210 4	0.077	0.232	0.307	0.307	0.077	$P^{(3)}$
1969 年	Ⅱ	4	0.181 7	0.25	0.334	0.083	0.25	0.083	$P^{(4)}$
1968 年	Ⅴ	5	0.191 8	0	0.5	0	0.2	0.3	$P^{(5)}$
	P_i（集对权重的加权和）			0.149	0.343	0.114	0.217	0.176	

表 4　1974 年入库流量预测

年份	状态	滞时/a	集对权重	各状态流量预测概率					概率来源
				Ⅰ	Ⅱ	Ⅲ	Ⅳ	Ⅴ	
1973 年	Ⅱ	1	0.209 8	0.25	0.25	0.083	0.083	0.334	$P^{(1)}$
1972 年	Ⅱ	2	0.206 3	0.167	0.417	0.083	0.25	0.083	$P^{(2)}$
1971 年	Ⅱ	3	0.210 4	0.334	0.334	0.083	0.083	0.166	$P^{(3)}$
1970 年	Ⅲ	4	0.181 7	0.077	0.308	0.231	0.231	0.153	$P^{(4)}$
1969 年	Ⅱ	5	0.191 8	0.25	0.25	0.333	0.167	0	$P^{(5)}$
	P_i（集对权重的加权和）			0.219	0.313	0.158	0.160	0.150	

年的入库流量预测状态为Ⅱ为偏枯年（$152 \leqslant X < 226$ m^3/s），与 1974 年的入库流量 224 m^3/s 相吻合。

2.5　各步长马尔可夫链的特性分析[7-8]

由于入库流量的马尔可夫链状态是相通的，即 $m \leftrightarrow n(m, n \in E, m \neq n)$，并且是非周期的，其全部状态构成一个闭集 C，即为该链的状态空间 E。通过分析该链是遍历的（非周期、不可约、正常返）。根据遍历原理，此链存在唯一的极限分布。即

$$\begin{cases} \pi_m = \sum_{n=1}^{M} \pi_m P_{mn} \\ \sum_{n=1}^{M} \pi_m = 1 \end{cases} \quad n = 1,2,\cdots M \tag{10}$$

利用小浪底水库 1919 年～1972 年的资料，以相对联系度最大的步长为 2 的马尔可夫链的特性分析，应用公式(10)求出极限分布，并根据极限分布可以求出各状态的重现期，即 $T_m = 1/\pi_m$，结果见表 5。

表 5　马尔可夫链的极限分布与各状态的重现期

状态	π_m	$T_m = 1/\pi_m$	状态	π_m	$T_m = 1/\pi_m$
Ⅰ	0.102 6	9.74	Ⅳ	0.210 3	4.75
Ⅱ	0.231 2	4.33	Ⅴ	0.193 4	5.17
Ⅲ	0.262 5	3.81			

由表 5 可见，各状态的重现期为 $T_1 = 9.74$，$T_2 = 4.33$，$T_3 = 3.81$，$T_4 = 4.75$，$T_5 = 5.17$。根据现有的实测资料，由本文有序样品聚类确定的分类标准及表 5 中的概率值分析，出现偏枯、中水和偏丰年的概率最大，总概率为 0.704。

3　结　语

应用实例结果表明，基于集对马尔可夫链对入库流量分布特征进行动态分析可有效分析径流序列的内在规律，使划分的年径流区间更合理；由于集对权重的马尔可夫链预测模型能充分考虑到原序列状态和滞时 k 步后序列状态之间的确定及不确定关系，有利于提高预测精度。

参考文献：

[1] 王文圣，李跃清，金菊良，等. 水文水资源集对分析[M]. 北京：科学出版社，2010.

[2] 覃光华，宋克超，周泽江，等. 基于 WA-GRNN 模型的年径流预测[J]. 四川大学学报：工程科学版，2013.

[3] 赵永龙，丁晶. 相空间小波网络模型及其在水文中长期预测中的应用[J]. 水科学进展，1998，9(3)：252-257.

[4] SEN Z. Critical Drought Analysis by Second Order Markov Chain[J]. Journal of Hydrology，1990，120(1-4)：183-202.

[5] 夏乐天，马尔可夫链预测方法及其在水文序列中的应用[D]. 南京：河海大学，2005.

[6] 汪明武，金菊良，周玉良. 集对分析耦合方法与应用[M]. 北京：科学出版社，2014.

[7] 夏乐天，梅雨强度的指数权马尔可夫链预测[J]. 水利学报，2005，36(8)：988-993.

[8] 潘刚，芦冰，邹兵，等. 马尔可夫链在水库主汛期降雨状态预测中的应用[J]. 水利科技与经济，2011，17(6)：33-36.

（责任编辑　陈　萍）